

[기술공통]

데이터 엔지니어링

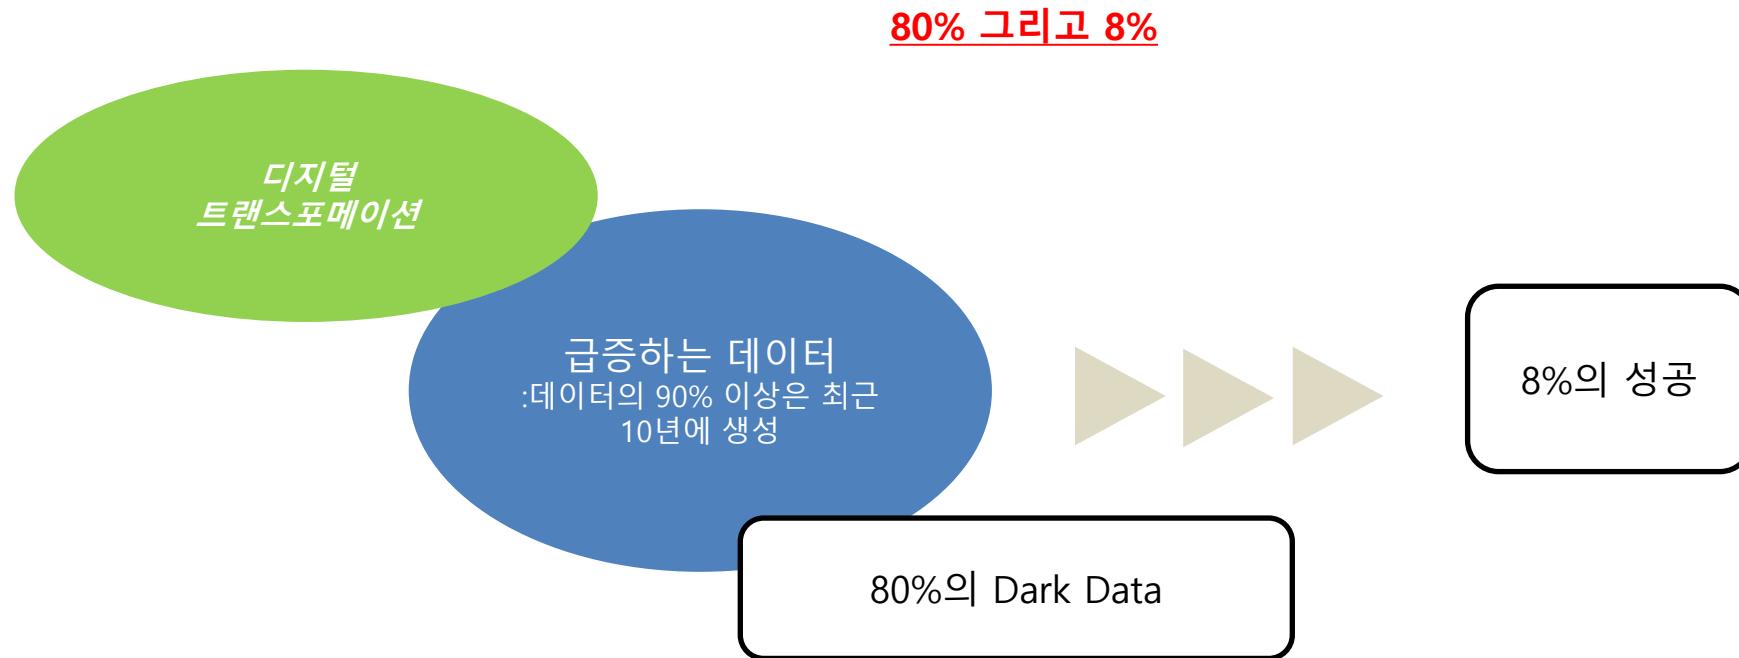


I. 데이터 시각화

1. 데이터 리터러시
2. 데이터 시각화

1. 데이터 리터러시

➤ 데이터? 빅데이터?



- Forrester
 - 글로벌 기업 데이터의 60~73%는 미활용
- 가트너
 - 80% 이상의 데이터 미활용
- IBM리서치
 - 88%이상 데이터 미활용

1. 데이터 리터러시

➤ 데이터 사일로(Data Silo)

➤ 데이터를 다루는 부서 간 서로 교류하지 않고 폐쇄적 성향을 띄는 상태

- 가트너, CDO 대상 설문조사(2018): 데이터 사일로가 데이터 활용의 걸림돌로 지목
- 액센츄어의 디지털 마케팅 설문조사(2018): 데이터 사일로가 데이터 활용의 걸림돌로 지목
-


1. 데이터 리터러시

- **데이터 리터러시(Data Literacy)**
 - 데이터를 읽고 이해하는 능력
 - 데이터를 건전한 목적과 윤리적 방법으로 사용하며, 현실 문제에 대한 끝없는 탐구를 통해 질문하고 답하는 능력
 - 데이터 기반 문제 정의, 데이터 획득, 데이터 해석, 분석 방안 선택, 전달과 공유 등 데이터 활용 전 과정에 걸쳐 필수
 - 가트너: 2020년, 80%이상의 주요 글로벌 기업이 데이터 리터러시에 집중

1. 데이터 리터러시

➤ Information Graphics

- 정보(information)와 그래픽스(graphics)의 합성어, 차트, 그래프, 아이콘, 이미지 활용하여 정보를 전달



Source: https://en.wikipedia.org/wiki/File:Minard_Update.png

2. 데이터시각화

➤ 데이터 시각화 중요성 증대

- ✓ 최근 데이터 Analytics의 중요성과 함께 분석 결과의 시각화에 대한 중요성 증가
- ✓ 효과적인 의사결정을 위해서는 인간이 정보를 잘 처리할 수 있도록 일목요연하고 효과적으로 자료를 제시하는 것이 필요
- ✓ 데이터 시각화의 역할은 점차 증대

Graphing: best way to understand your data, model to fit

2. 데이터시각화

- “숫자 계산은 정확하지만 그래프는 거칠다?”
 - ✓ Anscombe's quartet
 - ✓ 통계량으로 파악하기에는 거의 동일한 네 개의 데이터세트
(by the statistician Francis Anscombe in 1973)

I		II		III		IV	
x	y	x	y	x	y	x	y
10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
13.0	7.58	13.0	8.74	13.0	12.74	8.0	7.71
9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
11.0	8.33	11.0	9.26	11.0	7.81	8.0	8.47
14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
12.0	10.84	12.0	9.13	12.0	8.15	8.0	5.56
7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89

Source: Anscombe, F. J. (1973). Graphs in statistical analysis. *The american statistician*, 27(1), 17-21.


2. 데이터시각화

➤ Anscombe's quartet에 대한 통계량

Property	Value
네 개 자료의 X 평균	9
네 개 자료의 X 분산	11
네 개 자료의 Y 평균	7.50
네 개 자료의 Y 분산	4.122 or 4.127
네 개 자료의 X, Y 상관관계	0.816
네 개 자료의 X, Y 선형회귀식	$y = 3.00 + 0.500x$

2. 데이터시각화





➤ Anscombe's quartet 를 시각화 한다면?




2. 데이터시각화

➤ 다양한 그래프

- Histogram
- Barplot
- Scatter plot
- Box plot



- **웹을 통한 시각화**



12

1. 탐색적 데이터 분석
2. EDA를 위한 다양한 그래프
3. 효과적인 Data Visualization
4. Data Visualization과 EDA

1. 탐색적 데이터 분석(EDA)

- **탐색적 자료분석 (EDA, exploratory data analysis)**
데이터의 특징과 내재하는 구조를 알아내기 위한 분석




1. 탐색적 데이터 분석(EDA)

- **Data Analysis**
 - Exploration + Confirmatory Data Analysis로 구분
 - **Exploratory Data Analysis**
 - 데이터의 구조와 특징을 파악, 그 결과를 바탕으로 통계 모델링에 기여
 - 기술통계학(Descriptive Statistics): Data가 무엇을 보여주는 지를 이해
 - **Confirmatory Data Analysis (확증적 자료 분석)**
 - 유의성 검정, 신뢰구간 추정 등 통계적 추론을 하는 단계
 - 통계적 추론(Statistical Inference): 통계적 가설을 수립 후 그에 필요한 데이터를 수집하여 검정에 대한 강조

1. 탐색적 데이터 분석(EDA)

- *Exploratory Data Analysis* by John Tukey, 1977



John Tukey

1. 탐색적 데이터 분석(EDA)

- **Tukey가 정의한 Data Analysis (1961)**

"Procedures for analyzing data, techniques for interpreting the results of such procedures, ways of planning the gathering of data to make its analysis easier, more precise or more accurate, and all the machinery and results of (mathematical) statistics which apply to analyzing data."

- **Tukey가 생각하는 Visualization (1977)**

"The greatest value of a picture is when it forces us to notice what we never expected to see."

"Numerical quantities focus on expected values, graphical summaries on unexpected values."

1. 탐색적 데이터 분석(EDA)

- EDA는!
 - 가설/모형보다는 데이터에 대한 탐색에서 시작
 - 데이터의 분포나 값을 다양하게 시각화
 - 데이터에 대한 전체적 양상 및 기대하지 못했던 현상을 발견
 - 분석이 진행되며 문제에 대한 이해가 바뀔 수 있음
- EDA의 과정
 - 데이터에 대한 질문
 - 데이터 시각화, 데이터 변환 등을 통한 답의 발견
 - 위의 과정을 바탕으로 질문을 보완하여 답을 찾으며 새로운 질문을 제기



“데이터에 대한 이해도를 높임”

1. 탐색적 데이터 분석(EDA)

- EDA의 주요 역할
 - Resistance to outliers, missing values, or miscoded data
 - 평균 VS 중앙값
 - 일부 값의 파손에 저항적인 중앙값을 집중화 경향의 통계량으로 선호
 - Residual is a off-value from the main stream: Scatter plot!
 - Data Re-expression: 변수의 재표현, 변수 변환 등을 통해 선형성 또는 정규성을 만족
 - Graphic presentation: 다양한 그래프를 통한 데이터의 인사이트 발견

1. 탐색적 데이터 분석(EDA)

- EDA의 기대효과 및 확장
 - 데이터에 대한 관찰을 바탕으로 한 가설의 제안
 - 통계적 추론에 대한 평가
 - 적절한 통계적 도구와 기법 선택을 지원
 - Data Mining: 현대의 EDA



1. 탐색적 데이터 분석(EDA)





➤ Revisit on Anscombe's quartet

I		II		III		IV	
x	y	x	y	x	y	x	y
10.0	8.04	10.0	9.14	10.0	7.46	8.0	6.58
8.0	6.95	8.0	8.14	8.0	6.77	8.0	5.76
13.0	7.58	13.0	8.74	13.0	12.74	8.0	7.71
9.0	8.81	9.0	8.77	9.0	7.11	8.0	8.84
11.0	8.33	11.0	9.26	11.0	7.81	8.0	8.47
14.0	9.96	14.0	8.10	14.0	8.84	8.0	7.04
6.0	7.24	6.0	6.13	6.0	6.08	8.0	5.25
4.0	4.26	4.0	3.10	4.0	5.39	19.0	12.50
12.0	10.84	12.0	9.13	12.0	8.15	8.0	5.56
7.0	4.82	7.0	7.26	7.0	6.42	8.0	7.91
5.0	5.68	5.0	4.74	5.0	5.73	8.0	6.89

Source: Anscombe, F. J. (1973). Graphs in statistical analysis. *The american statistician*, 27(1), 17-21.

1. 탐색적 데이터 분석(EDA)


➤ Anscombe's quartet의 시각화



2. EDA를 위한 다양한 그래프

➤ Box Plot

- ✓ Tukey가 제안한 시각화
- ✓ 값의 분포를 표현



M – median

Q_1 , Q_3 – quartiles




Whiskers –

$1.5 * \text{interquartile range}$

Dots - outliers

2. EDA를 위한 다양한 그래프

- Bar Charts: 명목 변수를 시각화
- Line Charts: X축과 Y축(Response변수)에 변수 대응, Trends를 제시할 수 있음
- Pie Charts: 전체적으로 각 범주가 차지하는 비율 파악
- Bubble Charts: X, Y 두 변수 이 세 번째 변수 표현 시
- Stacked Charts: 시간에 따른 범주형 변수의 트렌드
- Scatterplots: 두 변수의 관계 제시
- Heatmap: 여러 변수를 보여주는 데 유리



3. 효과적인 Data Visualization

➤ **Data Visualization 가이드**

- ① Acquire
 - 데이터의 획득
- ② Parse
 - 데이터의 의미를 이해
- ③ Filter
 - 필요한 데이터만 필터링
- ④ Mine
 - 적절한 기법을 적용
- ⑤ Present
 - 기본 시각화를 적용
- ⑥ Refine
 - 시각화를 고도화
- ⑦ Interact
 - 데이터/변수를 제어하는 방법을 적용

3. 효과적인 Data Visualization

➤ Data Visualization 예시 (Source: *Visualizing Data* by Ben Fry (2008))

- 미국 우편번호 데이터의 시각화
- Acquire
 - 데이터의 획득: US Census Bureau 제공 Zipcode

00210	+43.005895	-071.013202	U	PORTSMOUTH	33	015
00211	+43.005895	-071.013202	U	PORTSMOUTH	33	015
00212	+43.005895	-071.013202	U	PORTSMOUTH	33	015
00213	+43.005895	-071.013202	U	PORTSMOUTH	33	015
00214	+43.005895	-071.013202	U	PORTSMOUTH	33	015
00215	+43.005895	-071.013202	U	PORTSMOUTH	33	015
00501	+40.922326	-072.637078	U	HOLTSVILLE	36	103
00544	+40.922326	-072.637078	U	HOLTSVILLE	36	103
00601	+18.165273	-066.722583		ADJUNTAS	72	001
00602	+18.393103	-067.180953		AGUADA	72	003
00603	+18.455913	-067.145780		AGUADILLA	72	005
00604	+18.493520	-067.135883		AGUADILLA	72	005
00605	+18.465162	-067.141486	P	AGUADILLA	72	005
00606	+18.172947	-066.944111		MARICAO	72	093
00610	+18.288685	-067.139696		ANASCO	72	011
00611	+18.279531	-066.802170	P	ANGELES	72	141
00612	+18.450674	-066.698262		ARECIBO	72	013
00613	+18.458093	-066.732732	P	ARECIBO	72	013
00614	+18.429675	-066.674506	P	ARECIBO	72	013
00616	+18.444792	-066.640678		BAJADERO	72	013

3. 효과적인 Data Visualization

➤ Data Visualization 예시 (Source: *Visualizing Data* by Ben Fry (2008))

- Parse
 - 데이터의 의미를 이해

00210	+43.005895	-071.013202	U	PORTSMOUTH	33	015						
string	TAB	float	TAB	float	TAB	character	TAB	string	TAB	index	TAB	index

01	ALABAMA	AL
02	ALASKA	AK
04	ARIZONA	AZ
05	ARKANSAS	AR
06	CALIFORNIA	CA
08	COLORADO	CO
09	CONNECTICUT	CT
10	DELAWARE	DE
12	FLORIDA	FL
13	GEORGIA	GA
15	HAWAII	HI
16	IDAHO	ID
17	ILLINOIS	IL
18	INDIANA	IN
19	IOWA	IA
20	KANSAS	KS

3. 효과적인 Data Visualization

➤ Data Visualization 예시 (Source: *Visualizing Data* by Ben Fry (2008))

- Filter
 - 필요한 데이터만 필터링: Alaska, Hawaii, Puerto Rico 등 제외
- Mine
 - 적절한 기법을 적용: 통계량 등을 통해 분석

00210	43.005895	-71.013202	PORTSMOUTH	NH
00211	43.005895	-71.013202	PORTSMOUTH	NH
00212	43.005895	-71.013202	PORTSMOUTH	NH
00213	43.005895	-71.013202	PORTSMOUTH	NH
00214	43.005895	-71.013202	PORTSMOUTH	NH
00215	43.005895	-71.013202	PORTSMOUTH	NH
00501	40.922326	-72.637078	HOLTSVILLE	NY
00544	40.922326	-72.637078	HOLTSVILLE	NY
.	.	.	.	.
.	.	.	.	.
.	.	.	.	.

↓

min
24.655691

max
48.987385


↓

min
-124.62608

max
-67.040764


3. 효과적인 Data Visualization

- Data Visualization 예시 (Source: *Visualizing Data* by Ben Fry (2008))
 - Present
 - 기본 시각화를 적용




3. 효과적인 Data Visualization

- Data Visualization 예시 (Source: *Visualizing Data* by Ben Fry (2008))
 - Refine
 - 시각화를 고도화




3. 효과적인 Data Visualization

- Data Visualization 예시 (Source: *Visualizing Data* by Ben Fry (2008))
 - Interact
 - 데이터/변수를 제어하는 방법을 적용



4. Data Visualization과 EDA

➤ Data Visualization의 발전



Source: *Handbook of Data Visualization* by Chen et al. (2008)

4. Data Visualization과 EDA

➤ Data Visualization의 발전

- 17세기, 천문, 설문, 지도, 항해 등의 분야에서 시각화의 발전(시간, 거리, 공간 등)
- 기하학과 좌표계의 발전




Figure 1.3. Scheiner's 1626 representation of the changes in sunspots over time. Source: Scheiner (1626–1630)




Figure 1.4. Langren's 1644 graph of determinations of the distance, in longitude, from Toledo to Rome. The correct distance is $16^{\circ}30'$. Source: Tufte (1997, p. 15)

Source: *Handbook of Data Visualization* by Chen et al. (2008)

4. Data Visualization과 EDA

- Data Visualization의 발전
 - 18세기, 데이터에 대한 시각화의 개념이 발전
 - 지도의 발전+인쇄술의 발전




Figure 1.5. A portion of Edmund Halley's *New and Correct Sea Chart Shewing the Variations in the Compass in the Western and Southern Ocean*, 1701. Source: Halley (1701), image from Palsky (1996, p. 41)

Source: *Handbook of Data Visualization* by Chen et al. (2008)

4. Data Visualization과 EDA

- Data Visualization의 발전
 - 18세기, 데이터에 대한 시각화의 개념이 발전
 - 지도의 발전+인쇄술의 발전




Figure 1.5. A portion of Edmund Halley's *New and Correct Sea Chart Shewing the Variations in the Compass in the Western and Southern Ocean*, 1701. Source: Halley (1701), image from Palsky (1996, p. 41)

William Playfair, 현대적인 시각화 시작
"Two different Vertical scales of different quantities"




Figure 1.6. Redrawn version of a portion of Playfair's 1801 pie-circle-line chart, comparing population and taxes in several nations




Figure 1.7. William Playfair's 1821 time-series graph of prices, wages and reigning ruler over a 250-year period. Source: Playfair (1821), image from Tufte (1983, p. 34)

Source: *Handbook of Data Visualization* by Chen et al. (2008)

4. Data Visualization과 EDA

➤ Data Visualization의 발전

- 19세기, 현대적인 시각화의 시작: Statistical graphics+Map
- 1850~1900: Statistical graphics의 황금기: 유럽 각 국의 통계청의 설립 및 산업화
 - Scale과 Shape의 다양한 변형, Log-log plot 등




Figure 1.8. A portion of Dr Robert Baker's cholera map of Leeds, 1833, showing the districts affected by cholera. Source: Gilbert (1958, Fig. 2)





Figure 1.10. Lallemand's *L'abaque du bateau "Le Triomphe"*, allowing determination of magnetic deviation at sea without calculation. Source: courtesy Mme Marie-Noëlle Maisonneuve, Les fonds anciens de la bibliothèque de l'École des Mines de Paris

Source: *Handbook of Data Visualization* by Chen et al. (2008)

4. Data Visualization과 EDA

➤ Data Visualization의 발전

- Francis Galton: x, y에 대한 Visual Analysis, isoline, contour 등의 활용, 다양한 시각화의 발전에 기여



A series of weather maps from the *Meteorographien*.

Figure 1.11. One page of Galton's 1863 multivariate weather chart of Europe showing barometric pressure, wind direction, rain and temperature for the month of December 1861. Source: Pearson (1914–1930, pl. 7)

Source: *Handbook of Data Visualization* by Chen et al.

4. Data Visualization과 EDA

- Data Visualization의 발전
 - 19세기




Figure 1.12. [This figure also appears in the color insert.] *Mouvement des voyageurs et des marchandises dans les principales stations de chemins de fer en 1882*. Scale: 2 mm² = 10 000 passengers or tons of freight. Source: *Album*, 1884, Plate II (author's collection)




Figure 1.13. Interstate migration shown by back-to-back barcharts, sorted by emigration. Source: *Statistical Atlas of the Eleventh Census, 1890*, diagram 66, p. 23 (author's collection)

Source: *Handbook of Data Visualization* by Chen et al.

4. Data Visualization과 EDA

- **Data Visualization의 발전**
 - 20세기 초반: Modern Dark Ages
 - 1950~1975: Rebirth of Data Visualization
 - John W. Tukey, "The future of data analysis" (1962)
 - EDA: stem-leaf plots, box-plots
 - Computer 발전에 따른 시각화의 발전: Fortran, mainframe...
- 1975~현재: High dimensional data, Interactive & Dynamic Data Visualization
 - Computing 발전
 - Data의 증가
 - EDA
 - Data Mining, Visual Data Mining

4. Data Visualization과 EDA

➤ Data Visualization의 발전






Figure 1.16. The distribution of milestone items over time, comparing trends in Europe and North America

Source: *Handbook of Data Visualization* by Chen et al.

4. Data Visualization과 EDA

➤ Data Visualization의 발전

- 주성분 분석
- ML의 결과 시각화
- ANN 시각화




There is no excuse for failing to plot and look!

Tukey

1. Grammar of Graphics
2. 기본 구성 요소
3. Data Visualization을 위한 Data Transformation

1. Grammar of Graphics

- **Statistical Graphics**
 - *Transdisciplinary field informed by Scientific, Statistical, Computing, Aesthetic, Psychological & Sociological Considerations*
 - Golden Age!
 - Exploratory Data Analysis (Tukey 1977)
 - Graphical Methods for Data Analysis (Chambers, Cleveland, Kleiner, and Tukey 1983)
 - The Visual Display of Quantitative Information (Tufte 1983)
 - The Elements of Graphing Data (Cleveland 1985)
- **Graphics for Communication**



1. Grammar of Graphics

Data Visualization & Graphics for Communication을 어떻게?
Grammar of Graphics



1. Grammar of Graphics

- **Grammar?**
 - 문법은 언어의 표현을 풍부하게 함
 - 그래픽의 문법은 시각화의 표현을 풍부하게 하여 표현의 범위를 확장
 - 그래픽을 다양한 관점에서 이해하는 토대를 제공
- **Grammar of Graphics**
 - 효과적인 시각화를 위한 도구이며, 그래픽의 구성요소를 설명
 - 체계적인 시각화를 통해 데이터에 내재된 구조를 이해하고 Insight를 얻을 수 있게 함

2. 기본 구성 요소

- **Basic Plot**
 - 다음의 데이터셋을 시각화한다면?
 - Scatterplot: A는 X축, C는 Y축 대응, D는 모양
 - Scatterplot 대신 line plot, bar plot 등 다양한 표현 가능

A	B	C	D
2	3	4	a
1	2	1	a
4	5	15	b
9	10	80	b



x	y	Shape
2	4	a
1	1	a
4	15	b
9	80	b

2. 기본 구성 요소

- **Basic Plot**

- x, y, shape을 실제 시각화될 값으로 변환
- 예: linear scale, Cartesian Coordinate system
 - X는 [0, 200], y는 [0, 300]으로 scale 조정
 - 경우에 따라서는 Statistical transformation 수행: binning, aggregating
 - a는 circle, b는 square





x	y	Shape
2	4	a
1	1	a
4	15	b
9	80	b

x	y	Shape
25	11	circle
0	0	circle
75	53	square
200	300	square

$$\text{floor}\left(\frac{x - \min(x)}{\text{range}(x)} * \text{screen width}\right).$$


2. 기본 구성 요소

- **Basic Plot**
 - Data, Scale과 Coordinate System, Plot annotation으로 시각화 생성
 - Plot annotation: plot title, backgrounds
 - Coordinate system: 축과 범례 생성



2. 기본 구성 요소

- 기본 구성 요소



2. 기본 구성 요소

- Data

- 시각화에 사용될 데이터
- 변수로 구성: 양적 및 질적 변수
- 2차원 정형 데이터



A	B	C	D
2	3	4	a
1	2	1	a
4	5	15	b
9	10	80	b


변수=Feature=속성

Observation
=Individual
=관측된 개체

ID	Score	Effect	Check
1	10	1	X
2	5	2	X
3	1	1	X
4	5	0.2	O

2. 기본 구성 요소

- **Aesthetics (시각적 속성)**
 - 데이터를 표현하는 시각적인 요소
 - 변수를 시각적 요소로 맵핑
 - 예: x축, y축, 크기, 색, 모양 등








Source: ggplot2의 diamonds 데이터셋

2. 기본 구성 요소

- **Geometric object**


- 데이터를 표현하려는 대상 / 모양
- 모든 Geometric object는 필요한 통계량이 지정: Histogram에는 bin 통계량
- 기본: 점, 텍스트 / 1차원: Line / 2차원: Polygon, interval
- Points, Lines, Bars, Areas, Arrows, ...



<#>

2. 기본 구성 요소

- **Coordinate System**
 - 데이터를 표현하려는 좌표계
 - 좌표계: 특정 공간에서 점이나 기하학적 요소를 고유하게 결정하고 표현하기 위해 하나 이상의 좌표를 사용하는 체계
 - Cartesian coordinate system: 데카르트 좌표계, 임의의 차원의 유클리드 공간을 표현
 - Polar coordinate system, Celestial coordinate system, log, map,



2. 기본 구성 요소

- Scales


- 데이터의 값들을 그래픽 공간의 값으로 맵핑
- 범례, 축 등 그래픽으로 부터 데이터를 이해하는 데 활용



- 예: 연속형 y scale은 공간에서 0부터 시작하여 큰 수가 위로 올라가는 것을 표현
- Linear VS Log



2. 기본 구성 요소

- **Statistics**
 - 통계량을 표현
 - 평균, 표준편차, Binning & Counting, ...
 - Diamonds 데이터셋에서 cut을 x축, carat을 y축
 - Y축의 값은 평균으로 표현



2. 기본 구성 요소

- Statistics
 - 두 변수에 대한 통계량을 제공하기도 함
 - Linear model의 직선이나 Loess 등을 표현




2. 기본 구성 요소

- Statistics

Name	Description
bin	Divide continuous range into bins, and count number of points in each
boxplot	Compute statistics necessary for boxplot
contour	Calculate contour lines
density	Compute 1d density estimate
identity	Identity transformation, $f(x) = x$
jitter	Jitter values by adding small random value
qq	Calculate values for quantile-quantile plot
quantile	Quantile regression
smooth	Smoothed conditional mean of y given x
summary	Aggregate values of y for given x
unique	Remove duplicated observations

2. 기본 구성 요소


- **Facet**
 - 하나 이상의 Discrete 변수의 값으로 Plot을 나누어 하위 Plot들로 표현
 - Facet into columns
 - Facet into rows
 - Facet into grid



<#>


2. 기본 구성 요소

- Theme
 - Grammar of Graphics에서 정의된 범위 외에서 필요한 그래픽의 구성 요소
 - 배경화면 색상, Grid의 선의 표현, 폰트, 그래픽 제목 등



2. 기본 구성 요소

- 기본 구성 요소
 - Data와 aesthetic mapping
 - Geometric objects
 - Scales
 - Facet Specification
 - Statistical Transformation
 - Coordinate system
- Layer
 - Data, mapping, statistical transformation, geometric objects
 - Plot에는 여러 layer가 있을 수 있음



1. 통계량의 이해

1. 통계량의 이해

➤ 통계량: 자료의 정리 및 요약

통계적 분석은...

...자료의 분포가 가지고 있는 특성을 찾아내서 그 특성을 숫자로 표시하기 위한 작업 (확률변수)

□ 분포의 특성



- 집중화 경향 (중심값 - 산술평균, 중앙값, 최빈값): 자료가 어느 위치에 집중되어 있는가를 나타냄
- 산포도 (범위, 분산, 표준편차, 백분위수): 자료가 산술평균을 중심으로 흩어져 있는 정도

이름	성별	나이	거주지	직업	요금	데이터 사용량	휴대폰 선호도	서비스 선호도
AAA	F	20	서울	회사원	55000	3GB	LG	5
BBB	F	19	인천	자영업	45000	9GB	삼성	4
CCC	M	25	김포	회사원	35000	1GB	샤오미	3
DDD	F	42	대전	회사원	75000	4GB	LG	5
EEE	F	27	서울	자영업	65000	2GB	소니	4
FFF	M	20	서울	회사원	55000	3GB	LG	5
GGG	M	43	서울	자영업	45000	9GB	삼성	4
HHH	M	25	대전	회사원	95000	11GB	샤오미	3
III	F	42	김포	회사원	45000	3GB	LG	5
JJJ	F	27	인천	자영업	40000	4GB	소니	4

1. 통계량의 이해

➤ 기술통계

- Descriptive Statistics
- 자료의 특성을 표, 그림, 통계량 등을 사용하여 쉽게 파악할 수 있도록 정리/요약, 자료를 요약하는 기초적 통계
- 예:
 - 중심위치의 측도: 표본평균, 중앙값
 - 산포의 측정: 분산, 표준편차, 사분위범위수, 백분위수, 변동계수, 평균의 표준오차
 - 분포의 형태에 관한 측도: 왜도(양수->왼쪽으로 치우친, 음수->우측으로 치우친),첨도



1. 통계량의 이해

➤ Measure of central tendency

– 평균(mean)

- (산술)평균(mean; arithmetic mean; average), 균형점(자료의 중심), 모든 관측값의 크기(정보)를 반영, 이상값(outlier)의 영향을 받음.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

– 중앙값(Median)

- 자료를 관측값의 크기순으로 배열하였을 경우, 중앙에 위치하는 관측값 이상값에 덜 민감
- 관측값의 수가 짝수이면 중앙의 두 관측값을 평균함.
- 50% percentile

– 최빈값(mode)

- 자료 중에서 가장 많이 출현하는 관측값
- 명목자료인 경우 평균과 중앙값은 무의미(예 : 허리사이즈)
- 존재하지 않을 수도 있으며, 1개 이상 존재할 수도 있음.

1. 통계량의 이해

➤ Measure of dispersion

– 필요성

- 자료를 대표값으로 요약/정리하는 것 만으로 충분하지 않음
- 자료에서 관측값들이 얼마만큼 퍼져있는가를 측정하는 척도인 산포도를 고려
- 산포도는 자료에서 관측값들이 변화하는 크기인 변동량을 나타내는 값

– 범위(range)

- 자료의 관측값 중 가장 큰 값인 최대값(max)과 가장 작은 값인 최소값(min)과의 차이
- 범위(range)=최대값(max)-최소값(min)
- 자료들 중 두 관측값만 이용하며 관측값 하나 하나의 크기가 반영되지 못함.
- 이상값에 의해 크게 영향 받음.

1. 통계량의 이해

➤ Measure of dispersion

– 분산과 표준편차

- 두 통계량 모두 각 자료가 평균에서 얼마나 퍼져있는지를 보는 정도, 관측값들이 자료의 중심인 평균으로부터 얼마나 떨어져 있는가의 척도, 즉 평균과 차이들의 평균

– 분산(Variance)

- 각 자료가 평균에서 얼마나 퍼져있는지를 보는 정도. 각 자료의 평균과의 차이에 대한 평균
- 모분산(population variance): 모집단으로부터 전수조사를 하여 얻은 관측값인 경우 모집단의 분산

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (X_i - \mu)^2$$

– 표본 분산(sample variance)

$$s^2 = \frac{1}{n-1} \sum_{i=1}^N (X_i - \bar{X})^2$$

– 표준편차

- 모분산이나 표본분산은 관측값들의 편차를 제공하여 계산하므로 모분산이나 표본분산의 측정단위는 관측값들의 측정단위와 일치하지 않으며, 그렇기 때문에 관측값의 측정단위와 일치시키기 위해서는 분산의 양의 제곱근을 사용

1. 통계량의 이해

➤ Measure of dispersion

-백분위수와 사분위수

- 평균과 표준편차는 자료의 분포에 대해 중요한 정보를 제공하지만, outlier 등의 영향을 받을 수 있으며, 자료 분포의 치우침 등에 대한 정보는 아님.
- Outlier나 Skewness 등에 영향을 받지 않고 자료를 파악하기 위해 median이나 interquartile range 등을 활용

-백분위수(Percentile)

- 자료를 크기 순서에 따라 나열한 자료를 100등분하는 수로, X 분위값이란 자료가 X%보다 작거나 같게 되는 값

-사분위수(Quartile)

- 백분위수가 25%, 50%, 75%인 경우

1. 통계량의 이해

➤ Measure of dispersion

– 공분산

- 분산은 한 변수에 대한 자료의 퍼짐이며, 두 변수간의 관계를 알기 위해 공분산을 사용
- 공분산은 X, Y가 각각의 평균들로부터 떨어진 거리, 변수의 편차간의 곱의 평균

$$\sigma(x, y) = E [(x - E[x])(y - E[y])],$$

– 상관관계:

- 두 변수의 공분산을 각 변수의 편차로 나눠서 -1~1 사이로 조정한 값
- Scaled version of the covariance between X and Y
- Pearson correlation

$$R = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum (X_i - \bar{X})^2 \sum (Y_i - \bar{Y})^2}}$$

- 상관관계는 -1~1사이의 값으로 Scale되며, 1은 두 변수 간 강한 상관관계가 있음을, 0은 두 변수가 관계가 없음을, -1은 두 변수간 음의 상관관계가 강하게 있음을 의미

